

سوال 1

Caffe برای تعریف مشخصات یک شبکه از فرمت protobuf شرکت گوگل (با پسوند prototxt) استفاده میکند. هر لایه بصورت جداگانه با ورودی و خروجی هایی که در اصل آرایه های چند بعدی هستند تعریف میشوند. به این نوع آرایه ها در Caffe اصطلاحاً blob گفته میشود که حاوی اطلاعات و داده های مورد نیاز هر لایه همانند مشتق ها و داده ها بوده و برای نقل و انتقال بهتر داده های بین لایه ها ایجاد شده است. لایه ها بصورت عمودی یکی بعد از دیگری قرار گرفته بطوری که لایه ورودی در پایین و لایه خروجی در بالا قرار میگیرد. هر لایه دارای تعداد مشخصی blob پایینی و بالایی با ابعاد مشخص است. با متصل کردن این blob ها و لایه ها است که یک شبکه عصبی عمیق ایجاد میشود.

2

در زیر با epoch 100 میبینیم

None

Train on 50000 samples, validate on 10000 samples

Epoch 1/200

50000/50000 [=====] - 4s 77us/step - loss: 1.7572 -
acc: 0.3643 - val_loss: 1.5335 - val_acc: 0.4450

Epoch 2/200

50000/50000 [=====] - 3s 69us/step - loss: 1.4540 -
acc: 0.4817 - val_loss: 1.5503 - val_acc: 0.4617

Epoch 3/200

50000/50000 [=====] - 3s 69us/step - loss: 1.3582 -
acc: 0.5161 - val_loss: 1.3539 - val_acc: 0.5161

Epoch 4/200

50000/50000 [=====] - 3s 69us/step - loss: 1.2922 -
acc: 0.5407 - val_loss: 1.3269 - val_acc: 0.5229

Epoch 5/200

50000/50000 [=====] - 3s 69us/step - loss: 1.2408 -
acc: 0.5608 - val_loss: 1.3133 - val_acc: 0.5324

Epoch 6/200

50000/50000 [=====] - 3s 69us/step - loss: 1.1914 -
acc: 0.5777 - val_loss: 1.3938 - val_acc: 0.5151

Epoch 7/200

50000/50000 [=====] - 3s 68us/step - loss: 1.1540 -
acc: 0.5909 - val_loss: 1.2765 - val_acc: 0.5509

Epoch 8/200

50000/50000 [=====] - 3s 69us/step - loss: 1.1154 -
acc: 0.6066 - val_loss: 1.3110 - val_acc: 0.5423

Epoch 9/200

50000/50000 [=====] - 3s 68us/step - loss: 1.0790 -

acc: 0.6202 - val_loss: 1.3902 - val_acc: 0.5259
Epoch 10/200
50000/50000 [=====] - 3s 68us/step - loss: 1.0521 -
acc: 0.6273 - val_loss: 1.2808 - val_acc: 0.5620
Epoch 11/200
50000/50000 [=====] - 3s 69us/step - loss: 1.0200 -
acc: 0.6384 - val_loss: 1.2912 - val_acc: 0.5592
Epoch 12/200
50000/50000 [=====] - 3s 67us/step - loss: 0.9927 -
acc: 0.6481 - val_loss: 1.2990 - val_acc: 0.5528
Epoch 13/200
50000/50000 [=====] - 3s 67us/step - loss: 0.9690 -
acc: 0.6558 - val_loss: 1.3048 - val_acc: 0.5567
Epoch 14/200
50000/50000 [=====] - 3s 67us/step - loss: 0.9371 -
acc: 0.6682 - val_loss: 1.3370 - val_acc: 0.5493
Epoch 15/200
50000/50000 [=====] - 3s 67us/step - loss: 0.9174 -
acc: 0.6745 - val_loss: 1.3259 - val_acc: 0.5590
Epoch 16/200
50000/50000 [=====] - 3s 67us/step - loss: 0.8857 -
acc: 0.6884 - val_loss: 1.3746 - val_acc: 0.5452
Epoch 17/200
50000/50000 [=====] - 3s 66us/step - loss: 0.8647 -
acc: 0.6941 - val_loss: 1.3743 - val_acc: 0.5510
Epoch 18/200
50000/50000 [=====] - 3s 66us/step - loss: 0.8413 -
acc: 0.7006 - val_loss: 1.3812 - val_acc: 0.5474
Epoch 19/200
50000/50000 [=====] - 3s 68us/step - loss: 0.8164 -
acc: 0.7105 - val_loss: 1.3849 - val_acc: 0.5604
Epoch 20/200
50000/50000 [=====] - 3s 69us/step - loss: 0.7951 -
acc: 0.7198 - val_loss: 1.4469 - val_acc: 0.5436
Epoch 21/200
50000/50000 [=====] - 3s 69us/step - loss: 0.7735 -
acc: 0.7251 - val_loss: 1.4514 - val_acc: 0.5447
Epoch 22/200
50000/50000 [=====] - 3s 68us/step - loss: 0.7509 -

acc: 0.7315 - val_loss: 1.4741 - val_acc: 0.5488
Epoch 23/200
50000/50000 [=====] - 3s 68us/step - loss: 0.7337 -
acc: 0.7401 - val_loss: 1.5145 - val_acc: 0.5441
Epoch 24/200
50000/50000 [=====] - 3s 69us/step - loss: 0.7078 -
acc: 0.7477 - val_loss: 1.5419 - val_acc: 0.5420
Epoch 25/200
50000/50000 [=====] - 3s 68us/step - loss: 0.6956 -
acc: 0.7541 - val_loss: 1.5662 - val_acc: 0.5456
Epoch 26/200
50000/50000 [=====] - 3s 68us/step - loss: 0.6686 -
acc: 0.7619 - val_loss: 1.5891 - val_acc: 0.5422
Epoch 27/200
50000/50000 [=====] - 3s 68us/step - loss: 0.6498 -
acc: 0.7706 - val_loss: 1.6254 - val_acc: 0.5392
Epoch 28/200
50000/50000 [=====] - 3s 68us/step - loss: 0.6268 -
acc: 0.7759 - val_loss: 1.6978 - val_acc: 0.5374
Epoch 29/200
50000/50000 [=====] - 3s 68us/step - loss: 0.6138 -
acc: 0.7799 - val_loss: 1.7882 - val_acc: 0.5313
Epoch 30/200
50000/50000 [=====] - 3s 69us/step - loss: 0.5990 -
acc: 0.7868 - val_loss: 1.7276 - val_acc: 0.5390
Epoch 31/200
50000/50000 [=====] - 3s 68us/step - loss: 0.5825 -
acc: 0.7924 - val_loss: 1.8404 - val_acc: 0.5250
Epoch 32/200
50000/50000 [=====] - 3s 69us/step - loss: 0.5605 -
acc: 0.7987 - val_loss: 1.8181 - val_acc: 0.5345
Epoch 33/200
50000/50000 [=====] - 3s 68us/step - loss: 0.5455 -
acc: 0.8049 - val_loss: 1.9132 - val_acc: 0.5190
Epoch 34/200
50000/50000 [=====] - 3s 68us/step - loss: 0.5315 -
acc: 0.8089 - val_loss: 1.8732 - val_acc: 0.5261
Epoch 35/200
50000/50000 [=====] - 3s 69us/step - loss: 0.5094 -

acc: 0.8172 - val_loss: 1.9989 - val_acc: 0.5291
Epoch 36/200
50000/50000 [=====] - 3s 69us/step - loss: 0.4930 -
acc: 0.8224 - val_loss: 1.9988 - val_acc: 0.5248
Epoch 37/200
50000/50000 [=====] - 3s 68us/step - loss: 0.4742 -
acc: 0.8316 - val_loss: 2.0715 - val_acc: 0.5209
Epoch 38/200
50000/50000 [=====] - 3s 69us/step - loss: 0.4605 -
acc: 0.8339 - val_loss: 2.1547 - val_acc: 0.5252
Epoch 39/200
50000/50000 [=====] - 3s 69us/step - loss: 0.4541 -
acc: 0.8373 - val_loss: 2.1792 - val_acc: 0.5249
Epoch 40/200
50000/50000 [=====] - 3s 68us/step - loss: 0.4356 -
acc: 0.8448 - val_loss: 2.1839 - val_acc: 0.5291
Epoch 41/200
50000/50000 [=====] - 3s 68us/step - loss: 0.4181 -
acc: 0.8500 - val_loss: 2.2588 - val_acc: 0.5330
Epoch 42/200
50000/50000 [=====] - 3s 69us/step - loss: 0.4033 -
acc: 0.8545 - val_loss: 2.3104 - val_acc: 0.5245
Epoch 43/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3837 -
acc: 0.8618 - val_loss: 2.3701 - val_acc: 0.5206
Epoch 44/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3784 -
acc: 0.8656 - val_loss: 2.4275 - val_acc: 0.5195
Epoch 45/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3649 -
acc: 0.8688 - val_loss: 2.4389 - val_acc: 0.5203
Epoch 46/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3525 -
acc: 0.8725 - val_loss: 2.4748 - val_acc: 0.5247
Epoch 47/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3392 -
acc: 0.8795 - val_loss: 2.6363 - val_acc: 0.5296
Epoch 48/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3305 -

acc: 0.8810 - val_loss: 2.6733 - val_acc: 0.5111
Epoch 49/200
50000/50000 [=====] - 3s 68us/step - loss: 0.3177 -
acc: 0.8839 - val_loss: 2.7036 - val_acc: 0.5264
Epoch 50/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2981 -
acc: 0.8932 - val_loss: 2.7693 - val_acc: 0.5232
Epoch 51/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2961 -
acc: 0.8940 - val_loss: 2.7302 - val_acc: 0.5301
Epoch 52/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2851 -
acc: 0.8976 - val_loss: 2.8693 - val_acc: 0.5275
Epoch 53/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2707 -
acc: 0.9027 - val_loss: 2.8965 - val_acc: 0.5220
Epoch 54/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2606 -
acc: 0.9060 - val_loss: 2.8983 - val_acc: 0.5212
Epoch 55/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2522 -
acc: 0.9103 - val_loss: 3.0672 - val_acc: 0.5270
Epoch 56/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2456 -
acc: 0.9125 - val_loss: 3.0826 - val_acc: 0.5262
Epoch 57/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2316 -
acc: 0.9176 - val_loss: 3.2134 - val_acc: 0.5147
Epoch 58/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2276 -
acc: 0.9183 - val_loss: 3.1649 - val_acc: 0.5149
Epoch 59/200
50000/50000 [=====] - 3s 69us/step - loss: 0.2233 -
acc: 0.9200 - val_loss: 3.2660 - val_acc: 0.5249
Epoch 60/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2215 -
acc: 0.9210 - val_loss: 3.2297 - val_acc: 0.5238
Epoch 61/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2067 -

acc: 0.9252 - val_loss: 3.3830 - val_acc: 0.5182
Epoch 62/200
50000/50000 [=====] - 3s 68us/step - loss: 0.2063 -
acc: 0.9261 - val_loss: 3.3989 - val_acc: 0.5286
Epoch 63/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1946 -
acc: 0.9308 - val_loss: 3.3306 - val_acc: 0.5348
Epoch 64/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1724 -
acc: 0.9389 - val_loss: 3.4732 - val_acc: 0.5197
Epoch 65/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1784 -
acc: 0.9362 - val_loss: 3.5480 - val_acc: 0.5232
Epoch 66/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1938 -
acc: 0.9309 - val_loss: 3.4987 - val_acc: 0.5256
Epoch 67/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1916 -
acc: 0.9331 - val_loss: 3.5611 - val_acc: 0.5096
Epoch 68/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1755 -
acc: 0.9371 - val_loss: 3.6047 - val_acc: 0.5219
Epoch 69/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1768 -
acc: 0.9382 - val_loss: 3.6823 - val_acc: 0.5162
Epoch 70/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1727 -
acc: 0.9385 - val_loss: 3.7010 - val_acc: 0.5234
Epoch 71/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1433 -
acc: 0.9494 - val_loss: 3.7083 - val_acc: 0.5236
Epoch 72/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1413 -
acc: 0.9498 - val_loss: 3.7483 - val_acc: 0.5204
Epoch 73/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1488 -
acc: 0.9480 - val_loss: 3.8760 - val_acc: 0.5248
Epoch 74/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1632 -

acc: 0.9435 - val_loss: 3.8198 - val_acc: 0.5250
Epoch 75/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1679 -
acc: 0.9400 - val_loss: 3.8667 - val_acc: 0.5213
Epoch 76/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1394 -
acc: 0.9511 - val_loss: 3.8686 - val_acc: 0.5275
Epoch 77/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1301 -
acc: 0.9537 - val_loss: 3.9140 - val_acc: 0.5299
Epoch 78/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1311 -
acc: 0.9554 - val_loss: 3.9044 - val_acc: 0.5288
Epoch 79/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1324 -
acc: 0.9538 - val_loss: 3.9430 - val_acc: 0.5268
Epoch 80/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1448 -
acc: 0.9508 - val_loss: 3.9561 - val_acc: 0.5307
Epoch 81/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1541 -
acc: 0.9478 - val_loss: 4.0163 - val_acc: 0.5279
Epoch 82/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1413 -
acc: 0.9508 - val_loss: 4.0231 - val_acc: 0.5292
Epoch 83/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1293 -
acc: 0.9542 - val_loss: 4.1030 - val_acc: 0.5282
Epoch 84/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1056 -
acc: 0.9631 - val_loss: 4.1522 - val_acc: 0.5258
Epoch 85/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1012 -
acc: 0.9654 - val_loss: 4.1555 - val_acc: 0.5244
Epoch 86/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0996 -
acc: 0.9662 - val_loss: 4.1926 - val_acc: 0.5285
Epoch 87/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0993 -

acc: 0.9655 - val_loss: 4.1953 - val_acc: 0.5264
Epoch 88/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1260 -
acc: 0.9567 - val_loss: 4.2703 - val_acc: 0.5285
Epoch 89/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1448 -
acc: 0.9501 - val_loss: 4.2402 - val_acc: 0.5205
Epoch 90/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1379 -
acc: 0.9530 - val_loss: 4.2937 - val_acc: 0.5216
Epoch 91/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1434 -
acc: 0.9507 - val_loss: 4.2865 - val_acc: 0.5242
Epoch 92/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1142 -
acc: 0.9603 - val_loss: 4.2989 - val_acc: 0.5221
Epoch 93/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1098 -
acc: 0.9631 - val_loss: 4.3559 - val_acc: 0.5304
Epoch 94/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1037 -
acc: 0.9643 - val_loss: 4.3805 - val_acc: 0.5217
Epoch 95/200
50000/50000 [=====] - 3s 69us/step - loss: 0.1053 -
acc: 0.9643 - val_loss: 4.2730 - val_acc: 0.5313
Epoch 96/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1064 -
acc: 0.9650 - val_loss: 4.4330 - val_acc: 0.5227
Epoch 97/200
50000/50000 [=====] - 3s 68us/step - loss: 0.1053 -
acc: 0.9652 - val_loss: 4.3214 - val_acc: 0.5273
Epoch 98/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0858 -
acc: 0.9707 - val_loss: 4.4786 - val_acc: 0.5195
Epoch 99/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0926 -
acc: 0.9690 - val_loss: 4.4278 - val_acc: 0.5306
Epoch 100/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0892 -

acc: 0.9694 - val_loss: 4.4363 - val_acc: 0.5277
Epoch 101/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0277 -
acc: 0.9918 - val_loss: 4.3869 - val_acc: 0.5357
Epoch 102/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0076 -
acc: 0.9990 - val_loss: 4.4294 - val_acc: 0.5385
Epoch 103/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0048 -
acc: 0.9997 - val_loss: 4.4518 - val_acc: 0.5386
Epoch 104/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0040 -
acc: 0.9997 - val_loss: 4.4723 - val_acc: 0.5403
Epoch 105/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0034 -
acc: 0.9998 - val_loss: 4.4957 - val_acc: 0.5413
Epoch 106/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0030 -
acc: 0.9998 - val_loss: 4.5007 - val_acc: 0.5409
Epoch 107/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0027 -
acc: 0.9998 - val_loss: 4.5151 - val_acc: 0.5402
Epoch 108/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0025 -
acc: 0.9999 - val_loss: 4.5288 - val_acc: 0.5412
Epoch 109/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0023 -
acc: 0.9999 - val_loss: 4.5457 - val_acc: 0.5412
Epoch 110/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0022 -
acc: 0.9999 - val_loss: 4.5581 - val_acc: 0.5410
Epoch 111/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0021 -
acc: 0.9999 - val_loss: 4.5685 - val_acc: 0.5416
Epoch 112/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0019 -
acc: 0.9999 - val_loss: 4.5773 - val_acc: 0.5418
Epoch 113/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0018 -

acc: 0.9999 - val_loss: 4.5871 - val_acc: 0.5416
Epoch 114/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0017 -
acc: 0.9999 - val_loss: 4.5961 - val_acc: 0.5396
Epoch 115/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0016 -
acc: 1.0000 - val_loss: 4.6005 - val_acc: 0.5426
Epoch 116/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0015 -
acc: 0.9999 - val_loss: 4.6080 - val_acc: 0.5415
Epoch 117/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0015 -
acc: 0.9999 - val_loss: 4.6201 - val_acc: 0.5417
Epoch 118/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0014 -
acc: 1.0000 - val_loss: 4.6266 - val_acc: 0.5410
Epoch 119/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0014 -
acc: 1.0000 - val_loss: 4.6327 - val_acc: 0.5410
Epoch 120/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0013 -
acc: 1.0000 - val_loss: 4.6413 - val_acc: 0.5416
Epoch 121/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0013 -
acc: 0.9999 - val_loss: 4.6471 - val_acc: 0.5417
Epoch 122/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0012 -
acc: 1.0000 - val_loss: 4.6500 - val_acc: 0.5419
Epoch 123/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0012 -
acc: 1.0000 - val_loss: 4.6583 - val_acc: 0.5418
Epoch 124/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0011 -
acc: 1.0000 - val_loss: 4.6658 - val_acc: 0.5420
Epoch 125/200
50000/50000 [=====] - 3s 68us/step - loss: 0.0011 -
acc: 1.0000 - val_loss: 4.6710 - val_acc: 0.5419
Epoch 126/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0011 -

acc: 1.0000 - val_loss: 4.6790 - val_acc: 0.5426
Epoch 127/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0010 -
acc: 1.0000 - val_loss: 4.6801 - val_acc: 0.5420
Epoch 128/200
50000/50000 [=====] - 3s 69us/step - loss: 0.0010 -
acc: 1.0000 - val_loss: 4.6885 - val_acc: 0.5433
Epoch 129/200
50000/50000 [=====] - 3s 68us/step - loss:
9.7890e-04 - acc: 1.0000 - val_loss: 4.6941 - val_acc: 0.5425
Epoch 130/200
50000/50000 [=====] - 3s 68us/step - loss:
9.4352e-04 - acc: 1.0000 - val_loss: 4.6991 - val_acc: 0.5426
Epoch 131/200
50000/50000 [=====] - 3s 68us/step - loss:
9.2100e-04 - acc: 1.0000 - val_loss: 4.7023 - val_acc: 0.5433
Epoch 132/200
50000/50000 [=====] - 3s 68us/step - loss:
8.9893e-04 - acc: 1.0000 - val_loss: 4.7064 - val_acc: 0.5428
Epoch 133/200
50000/50000 [=====] - 3s 68us/step - loss:
8.7421e-04 - acc: 1.0000 - val_loss: 4.7121 - val_acc: 0.5432
Epoch 134/200
50000/50000 [=====] - 3s 69us/step - loss:
8.6032e-04 - acc: 1.0000 - val_loss: 4.7153 - val_acc: 0.5432
Epoch 135/200
50000/50000 [=====] - 3s 69us/step - loss:
8.2716e-04 - acc: 1.0000 - val_loss: 4.7215 - val_acc: 0.5433
Epoch 136/200
50000/50000 [=====] - 3s 68us/step - loss:
8.0585e-04 - acc: 1.0000 - val_loss: 4.7252 - val_acc: 0.5451
Epoch 137/200
50000/50000 [=====] - 3s 68us/step - loss:
7.9714e-04 - acc: 1.0000 - val_loss: 4.7268 - val_acc: 0.5430
Epoch 138/200
50000/50000 [=====] - 3s 69us/step - loss:
7.8329e-04 - acc: 1.0000 - val_loss: 4.7344 - val_acc: 0.5438
Epoch 139/200
50000/50000 [=====] - 3s 69us/step - loss:

7.6205e-04 - acc: 1.0000 - val_loss: 4.7396 - val_acc: 0.5431
Epoch 140/200
50000/50000 [=====] - 3s 69us/step - loss:
7.5152e-04 - acc: 1.0000 - val_loss: 4.7416 - val_acc: 0.5430
Epoch 141/200
50000/50000 [=====] - 3s 68us/step - loss:
7.3050e-04 - acc: 1.0000 - val_loss: 4.7442 - val_acc: 0.5429
Epoch 142/200
50000/50000 [=====] - 3s 69us/step - loss:
7.2061e-04 - acc: 1.0000 - val_loss: 4.7475 - val_acc: 0.5434
Epoch 143/200
50000/50000 [=====] - 3s 69us/step - loss:
6.9807e-04 - acc: 1.0000 - val_loss: 4.7502 - val_acc: 0.5438
Epoch 144/200
50000/50000 [=====] - 3s 69us/step - loss:
6.8362e-04 - acc: 1.0000 - val_loss: 4.7563 - val_acc: 0.5430
Epoch 145/200
50000/50000 [=====] - 3s 69us/step - loss:
6.7499e-04 - acc: 1.0000 - val_loss: 4.7578 - val_acc: 0.5436
Epoch 146/200
50000/50000 [=====] - 3s 69us/step - loss:
6.6336e-04 - acc: 1.0000 - val_loss: 4.7605 - val_acc: 0.5429
Epoch 147/200
50000/50000 [=====] - 3s 69us/step - loss:
6.5426e-04 - acc: 1.0000 - val_loss: 4.7647 - val_acc: 0.5439
Epoch 148/200
50000/50000 [=====] - 3s 69us/step - loss:
6.3654e-04 - acc: 1.0000 - val_loss: 4.7658 - val_acc: 0.5434
Epoch 149/200
50000/50000 [=====] - 3s 68us/step - loss:
6.2240e-04 - acc: 1.0000 - val_loss: 4.7705 - val_acc: 0.5432
Epoch 150/200
50000/50000 [=====] - 3s 69us/step - loss:
6.1489e-04 - acc: 1.0000 - val_loss: 4.7749 - val_acc: 0.5432
Epoch 151/200
50000/50000 [=====] - 3s 68us/step - loss:
5.9721e-04 - acc: 1.0000 - val_loss: 4.7756 - val_acc: 0.5435
Epoch 152/200
50000/50000 [=====] - 3s 68us/step - loss:


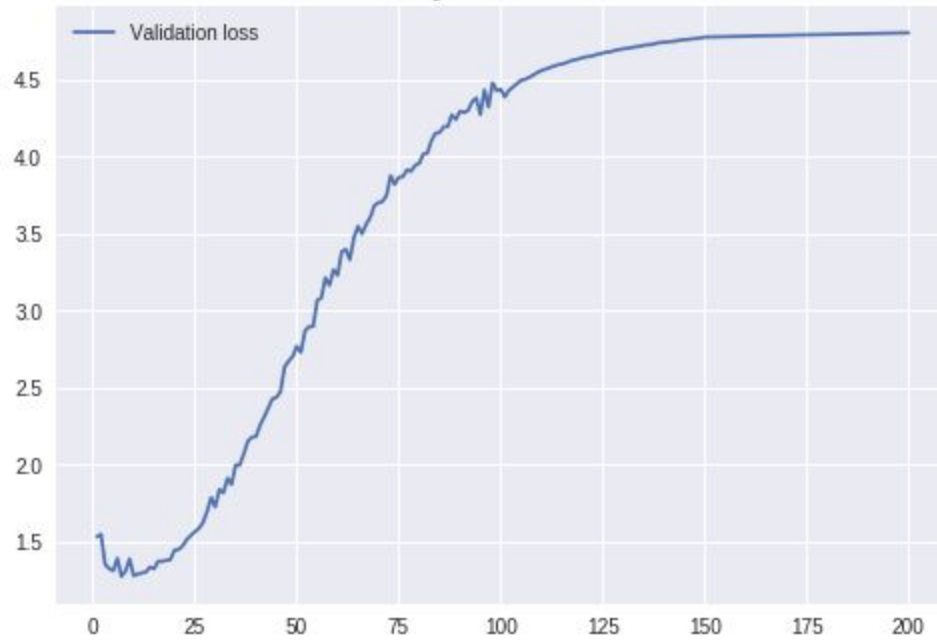
5.8889e-04 - acc: 1.0000 - val_loss: 4.7761 - val_acc: 0.5434
Epoch 153/200
50000/50000 [=====] - 3s 68us/step - loss:
5.8541e-04 - acc: 1.0000 - val_loss: 4.7765 - val_acc: 0.5439
Epoch 154/200
50000/50000 [=====] - 3s 68us/step - loss:
5.8320e-04 - acc: 1.0000 - val_loss: 4.7777 - val_acc: 0.5429
Epoch 155/200
50000/50000 [=====] - 3s 68us/step - loss:
5.8112e-04 - acc: 1.0000 - val_loss: 4.7778 - val_acc: 0.5439
Epoch 156/200
50000/50000 [=====] - 3s 69us/step - loss:
5.7928e-04 - acc: 1.0000 - val_loss: 4.7788 - val_acc: 0.5436
Epoch 157/200
50000/50000 [=====] - 3s 69us/step - loss:
5.7708e-04 - acc: 1.0000 - val_loss: 4.7793 - val_acc: 0.5436
Epoch 158/200
50000/50000 [=====] - 3s 69us/step - loss:
5.7540e-04 - acc: 1.0000 - val_loss: 4.7797 - val_acc: 0.5437
Epoch 159/200
50000/50000 [=====] - 3s 68us/step - loss:
5.7367e-04 - acc: 1.0000 - val_loss: 4.7801 - val_acc: 0.5436
Epoch 160/200
50000/50000 [=====] - 3s 68us/step - loss:
5.7146e-04 - acc: 1.0000 - val_loss: 4.7811 - val_acc: 0.5440
Epoch 161/200
50000/50000 [=====] - 3s 69us/step - loss:
5.7068e-04 - acc: 1.0000 - val_loss: 4.7819 - val_acc: 0.5434
Epoch 162/200
50000/50000 [=====] - 3s 69us/step - loss:
5.6830e-04 - acc: 1.0000 - val_loss: 4.7821 - val_acc: 0.5440
Epoch 163/200
50000/50000 [=====] - 3s 69us/step - loss:
5.6634e-04 - acc: 1.0000 - val_loss: 4.7830 - val_acc: 0.5434
Epoch 164/200
50000/50000 [=====] - 3s 68us/step - loss:
5.6460e-04 - acc: 1.0000 - val_loss: 4.7841 - val_acc: 0.5432
Epoch 165/200
50000/50000 [=====] - 3s 69us/step - loss:



5.6307e-04 - acc: 1.0000 - val_loss: 4.7840 - val_acc: 0.5435
Epoch 166/200
50000/50000 [=====] - 3s 68us/step - loss:
5.6113e-04 - acc: 1.0000 - val_loss: 4.7849 - val_acc: 0.5432
Epoch 167/200
50000/50000 [=====] - 3s 68us/step - loss:
5.5949e-04 - acc: 1.0000 - val_loss: 4.7850 - val_acc: 0.5437
Epoch 168/200
50000/50000 [=====] - 3s 68us/step - loss:
5.5784e-04 - acc: 1.0000 - val_loss: 4.7858 - val_acc: 0.5432
Epoch 169/200
50000/50000 [=====] - 3s 69us/step - loss:
5.5609e-04 - acc: 1.0000 - val_loss: 4.7859 - val_acc: 0.5437
Epoch 170/200
50000/50000 [=====] - 3s 68us/step - loss:
5.5426e-04 - acc: 1.0000 - val_loss: 4.7870 - val_acc: 0.5430
Epoch 171/200
50000/50000 [=====] - 3s 69us/step - loss:
5.5233e-04 - acc: 1.0000 - val_loss: 4.7877 - val_acc: 0.5433
Epoch 172/200
50000/50000 [=====] - 3s 70us/step - loss:
5.5099e-04 - acc: 1.0000 - val_loss: 4.7879 - val_acc: 0.5434
Epoch 173/200
50000/50000 [=====] - 3s 69us/step - loss:
5.4929e-04 - acc: 1.0000 - val_loss: 4.7890 - val_acc: 0.5430
Epoch 174/200
50000/50000 [=====] - 3s 69us/step - loss:
5.4812e-04 - acc: 1.0000 - val_loss: 4.7892 - val_acc: 0.5436
Epoch 175/200
50000/50000 [=====] - 3s 68us/step - loss:
5.4581e-04 - acc: 1.0000 - val_loss: 4.7896 - val_acc: 0.5439
Epoch 176/200
50000/50000 [=====] - 3s 68us/step - loss:
5.4478e-04 - acc: 1.0000 - val_loss: 4.7902 - val_acc: 0.5437
Epoch 177/200
50000/50000 [=====] - 3s 69us/step - loss:
5.4264e-04 - acc: 1.0000 - val_loss: 4.7907 - val_acc: 0.5437
Epoch 178/200
50000/50000 [=====] - 3s 69us/step - loss:

5.4124e-04 - acc: 1.0000 - val_loss: 4.7914 - val_acc: 0.5436
Epoch 179/200
50000/50000 [=====] - 3s 69us/step - loss:
5.3934e-04 - acc: 1.0000 - val_loss: 4.7921 - val_acc: 0.5433
Epoch 180/200
50000/50000 [=====] - 3s 69us/step - loss:
5.3815e-04 - acc: 1.0000 - val_loss: 4.7926 - val_acc: 0.5428
Epoch 181/200
50000/50000 [=====] - 3s 69us/step - loss:
5.3665e-04 - acc: 1.0000 - val_loss: 4.7929 - val_acc: 0.5438
Epoch 182/200
50000/50000 [=====] - 3s 68us/step - loss:
5.3494e-04 - acc: 1.0000 - val_loss: 4.7938 - val_acc: 0.5437
Epoch 183/200
50000/50000 [=====] - 3s 68us/step - loss:
5.3326e-04 - acc: 1.0000 - val_loss: 4.7943 - val_acc: 0.5427
Epoch 184/200
50000/50000 [=====] - 3s 69us/step - loss:
5.3166e-04 - acc: 1.0000 - val_loss: 4.7945 - val_acc: 0.5437
Epoch 185/200
50000/50000 [=====] - 3s 68us/step - loss:
5.3018e-04 - acc: 1.0000 - val_loss: 4.7951 - val_acc: 0.5438
Epoch 186/200
50000/50000 [=====] - 3s 68us/step - loss:
5.2873e-04 - acc: 1.0000 - val_loss: 4.7956 - val_acc: 0.5435
Epoch 187/200
50000/50000 [=====] - 3s 68us/step - loss:
5.2725e-04 - acc: 1.0000 - val_loss: 4.7963 - val_acc: 0.5435
Epoch 188/200
50000/50000 [=====] - 3s 68us/step - loss:
5.2539e-04 - acc: 1.0000 - val_loss: 4.7964 - val_acc: 0.5434
Epoch 189/200
50000/50000 [=====] - 3s 69us/step - loss:
5.2422e-04 - acc: 1.0000 - val_loss: 4.7976 - val_acc: 0.5434
Epoch 190/200
50000/50000 [=====] - 3s 69us/step - loss:
5.2238e-04 - acc: 1.0000 - val_loss: 4.7980 - val_acc: 0.5435
Epoch 191/200
50000/50000 [=====] - 3s 69us/step - loss:

5.2101e-04 - acc: 1.0000 - val_loss: 4.7984 - val_acc: 0.5434
Epoch 192/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1970e-04 - acc: 1.0000 - val_loss: 4.7993 - val_acc: 0.5428
Epoch 193/200
50000/50000 [=====] - 3s 68us/step - loss:
5.1830e-04 - acc: 1.0000 - val_loss: 4.7999 - val_acc: 0.5433
Epoch 194/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1658e-04 - acc: 1.0000 - val_loss: 4.8001 - val_acc: 0.5434
Epoch 195/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1531e-04 - acc: 1.0000 - val_loss: 4.8010 - val_acc: 0.5428
Epoch 196/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1386e-04 - acc: 1.0000 - val_loss: 4.8010 - val_acc: 0.5435
Epoch 197/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1250e-04 - acc: 1.0000 - val_loss: 4.8015 - val_acc: 0.5431
Epoch 198/200
50000/50000 [=====] - 3s 69us/step - loss:
5.1085e-04 - acc: 1.0000 - val_loss: 4.8022 - val_acc: 0.5430
Epoch 199/200
50000/50000 [=====] - 3s 68us/step - loss:
5.0949e-04 - acc: 1.0000 - val_loss: 4.8029 - val_acc: 0.5431
Epoch 200/200
50000/50000 [=====] - 3s 68us/step - loss:
5.0812e-04 - acc: 1.0000 - val_loss: 4.8031 - val_acc: 0.5433
10000/10000 [=====] - 1s 82us/step
ssss
[[3 8 0 ... 5 7 7

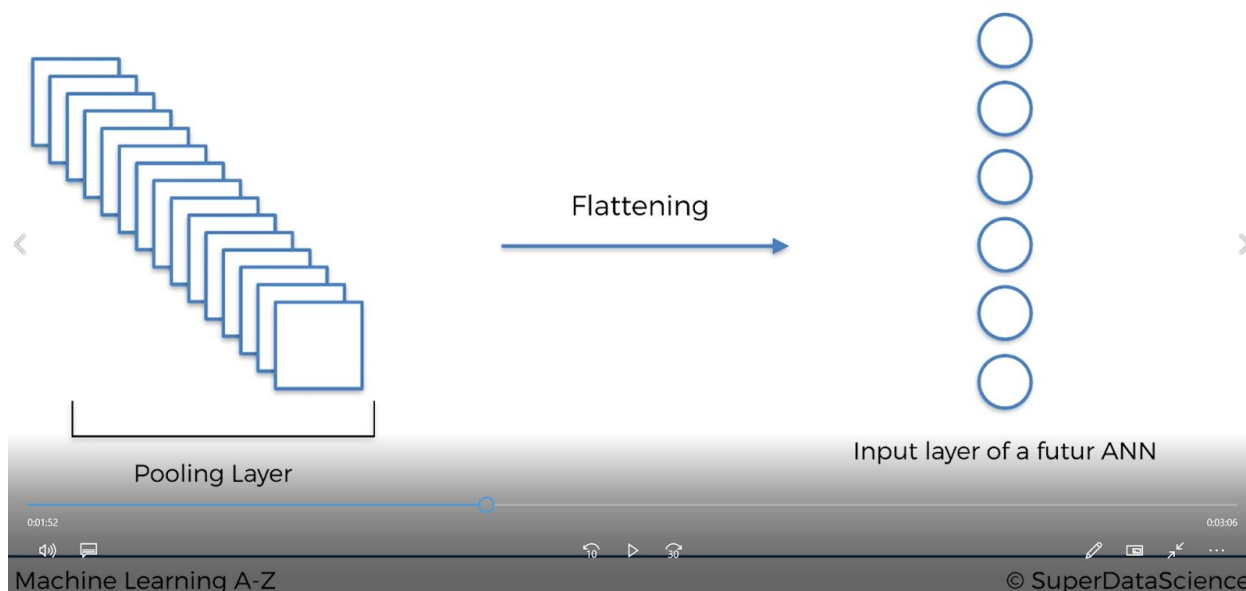
Training and validation loss



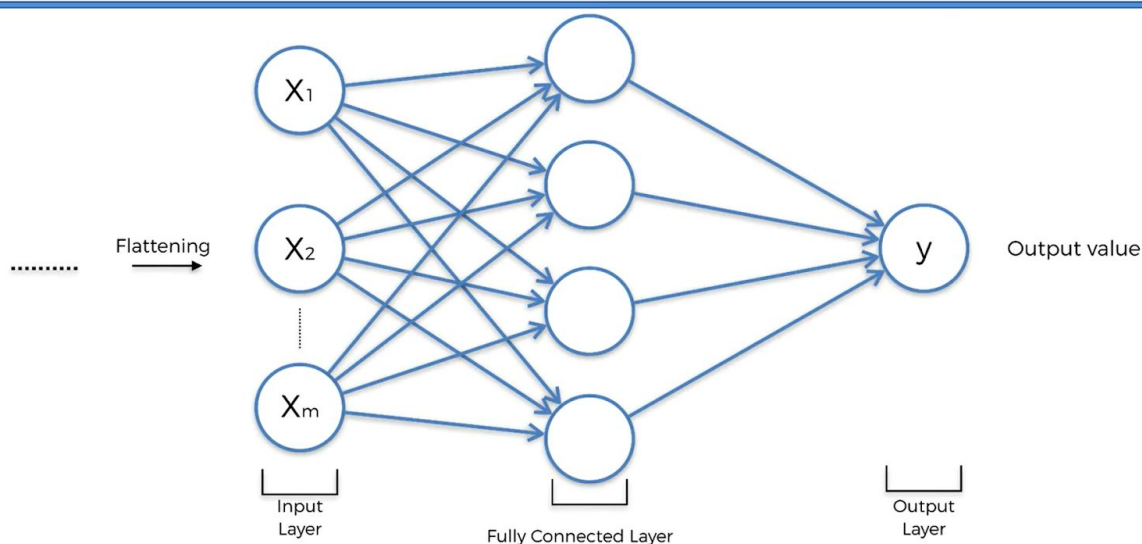


میدانیم برای لایه convd داریم

Step 3 - Flattening



Step 4 - Full Connection



در هر تکرار از عمل بهینه سازی، مراحل زیر اتفاق می افتند :

1. فاز **forward** شبکه برای محاسبه خروجی و خطای شبکه فراخوانی میشود.
2. فاز **backward** شبکه برای محاسبه گرادیانت ها فراخوانی میشود.
3. گرادیانت ها در بروزآوری پارامترها با توجه به روش مشخص شده در **solver** اعمال میشوند.

4. وضعیت solver با توجه به نرخ یادگیری، تاریخچه و روش مشخص شده بروز آوری میشود تا وزنهای را از مقداردهی اولیه به مدل یاد گرفته شده منتقل کند.

Solver ها را نیز همانند مدلها با استفاده از CPU و یا GPU اجرا کرد که در اینجا از google colab استفاده کردیم.

بقیه	توضیحات	این	سوال	عین	دز
https://deeplearning.ir/%D8%A2%D9%85%D9%88%D8%B2%D8%B4-caffe-%D8%A8/%D8%AE%D8%B4-%D8%AF%D9%88%D9%85-solver-%D9%87%D8%A7					

آمده بنابراین در زمان تحویل به صورت کامل گفته میشود

ر خط اول مشخص میکنیم که آموزش با نرخ یادگیری ۰,۰۱ شروع شود

در خط دوم سیاست نرخ یادگیری را مشخص میکنیم, در این قسمت ما مشخص کردیم که نرخ یادگیری طی گام هایی (steps) کاهش یابد. در ادامه بیشتر درمورد این گزینه صحبت میکنیم.

خط سوم , همان ضریب کاهش نرخ یادگیری است که در هر گام انجام میشود. در این قسمت است که مشخص میکنیم نرخ یادگیری با چه ضریبی کاهش پیدا کند. در اینجا ما مشخص کردیم که نرخ یادگیری با ضریب ۱۰ کاهش پیدا کند (یعنی نرخ یادگیری در مقدار gama که مساوی ۰,۱ است ضرب شود)

خط چهارم همان تعداد گام هایی است که نرخ یادگیری در آنها باید کاهش یابد. در اینجا این مقدار برابر با ۱۰۰ هزار است. یعنی هر ۱۰۰ هزار تکرار, نرخ یادگیری را کاهش بده.

خط پنجم هم تعداد تکرار مراحل آموزش را مشخص میکند. در اینجا یعنی ۳۵۰ هزار بار آموزش را تکرار کن .

خط آخر نیز مقدار momentum را مشخص کرده است.

تحت تنظیمات بالا, ما همیشه از momentum با مقدار $\mu = 0.9$ استفاده میکنیم. ما آموزش را با نرخ یادگیری پایه (base_lr $\alpha = 0.01 = 10^{-2}$) برای ۱۰۰ هزار تکرار اول شروع میکنیم و سپس نرخ یادگیری را با مقدار γ (gama ضرب کرده و آموزش را با نرخ یادگیری

$$\alpha' = \alpha \gamma = (0.01). (0.1) = 0.001 = 10^{-3}$$

برای ۱۰۰ هزار تکرار بعدی (۱۰۰-۲۰۰)

$$\alpha'' = 10^{-4}$$

(ادامه میدهیم . به همین صورت برای تکرار های ۲۰۰ هزار تا ۳۰۰ هزار از نرخ یادگیری)

$$\alpha''' = 10^{-5}$$

استفاده کرده و نهایتاً از نرخ یادگیری — برای تکرار های باقی مانده (۳۰۰ تا ۳۵۰ هزار) استفاده میکنیم .

لطفا دقت کنید که مقدار momentum می که تنظیم میکنید اندازه آپدیت شما را بعد از تعداد زیادی تکرار آموزش با

ضریب $\frac{1}{1-\mu}$ ضرب میکند. بنابر این اگر مقدار μ را افزایش دادید بهتر است مقدار α را نیز به همان نسبت کاهش دهید.

بعنوان مثال, فرض کنید مقدار momentum ما $\mu = 0.9$ باشد. در اینصورت ما ضریبی آپدیتی برابر با

$$\frac{1}{1-0.9} = 10$$

داریم یعنی مقدار آپدیت ما هرچه باشد در این ضریب ضرب خواهد شد. حال اگر مقدار momentum را به $\mu = 0.99$ افزایش دهیم, ما با اینکار ضریب اندازه آپدیت را ۱۰۰ برابر افزایش داده ایم و باید α (base_lr) را با ضریب ۱۰ کاهش دهیم.

همچنین دقت کنید که تنظیمات بالا تنها حکم راهنما را داشته و اینطور نیست که بهترین تنظیمات تحت هر شرایط و برای هر کاری باشند. اگر متوجه شدید که یادگیری شروع به بد شدن (diverge) کرده است (بعنوان مثال مشاهده میکنید که مقادیر خطای شبکه و یا خروجی همگی Nan و یا inf میشوند و این مسئله هم بسیار زیاد دارد تکرار میشود) سعی کنید مقدار base_lr را کاهش دهید (مثلا مقداری برابر با 0.001 base_lr) و عمل آموزش را تکرار کنید. انقدر این عمل را تکرار کنید تا به base_lr برسید که عملا برایتان کار کند.

سیاست های نرخ یادگیری

در Caffe میتوان سیاست های مختلفی برای کاهش نرخ یادگیری لحاظ کرد. شما میتوانید در زیر لیستی از این سیاست ها و نحوه عملکرد آنها را مشاهده کنید.

- fixed : همیشه از base_lr استفاده میکند. (مقدار نرخ یادگیری ثابت است)
- step : نرخ یادگیری از رابطه $\text{base_lr} * \gamma^{\lfloor \text{iter} / \text{step} \rfloor}$ بدست می آید
- exp : نرخ یادگیری از رابطه $\text{base_lr} * \gamma^{\text{ite}}$ بدست می آید
- inv : نرخ یادگیری از رابطه $\text{base_lr} * (1 + \gamma * \text{iter})^{-\text{power}}$ بدست می آید
- multistep : مثل step عمل کرده با این تفاوت که اجازه تعریف گامهای غیریکسان در stepvalue میدهد
- poly : در این روش نرخ یادگیری از یک کاهش چند جمله ای تبعیت کرده و با رسیدن به max_iter صفر میشود, نرخ یادگیری در این روش از رابطه $\text{base_lr} * (1 - \text{iter}/\text{max_iter})^{\text{power}}$ بدست می آید.
- sigmoid : در این روش نرخ یادگیری از یک کاهش سیگموئیدی تبعیت کرده از رابطه $\text{base_lr} * \left(\frac{1}{1 + \exp(-\gamma * (\text{iter} - \text{stepsiz}))} \right)$ بدست می آید

لطفا دقت کنید که در صورت انتخاب هر کدام از موارد فوق بعنوان `lr_policy` در `solver` , اطمینان حاصل کنید تمامی پارامترهای مورد نیاز آنها (مواردی که در رابطه آورده شده اند) را فراهم کنید. بعنوان مثال اگر قصد استفاده از `poly` را دارید باید پارامترهای `max_iter` , `iter` , `base_lr` و `power` را نیز فراهم کنید.

این سیاستها به همراه توضیحات هریک در فایل [Caffe.proto](#) که بیشتر توضیح دادیم قرار دارد و برای فهمیدن اینکه آیا سیاست جدیدی اضافه شده است یا خیر و یا مشاهده اینکه یک سیاست به چه صورت در `caffe` عمل میکند میتوان به این فایل مراجعه کرد.

b 2

دقت ان بالا میروود مثلا در normalization


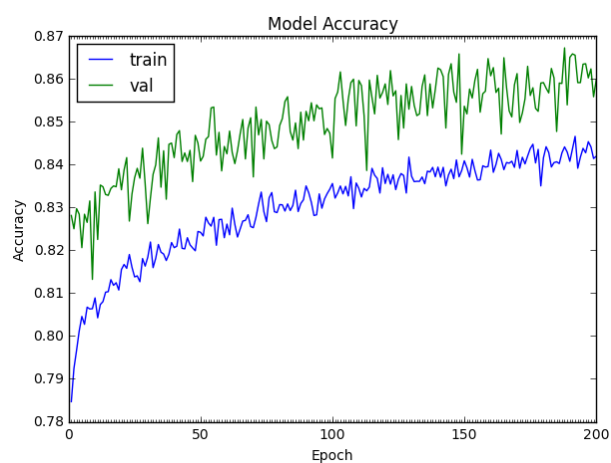
مفهومی داریم بنام **Lateral inhibition** که به فارسی شاید گفت منع جانبی . یعنی چی؟ این مفهوم به ظرفیت یک نورون برانگیخته شده برای بی اثر کردن (یا کاهش اثر) همسایه هاش اشاره دارد. اساسا ما به یه افزایش قابل توجه نیاز داریم تا یه شکلی از ماکسیمای محلی داشته باشیم . این مسئله باعث ایجاد کنتراست در اون ناحیه میشه و بنابر این بلطبع باعث افزایش درک حسی (یا **sensory perception**) میشه. افزایش درک حسی چیز خوبیه برای همین هم در ابتدا در شبکه کانولوشن سعی در پیاده سازیش کردن .

این لایه این مفهوم رو که تازه صحبتش رو کردیم سعی میکنه پیاده کنه . این لایه زمانی که ما با نورونهای **ReLU** سرو کار داریم مفید هست دلایلش هم اینه که نورونهای **ReLU** فعالسازی های نامحدود (**unbounded**) دارن و ما به **LNR** نیاز داریم تا اوناو نرمالیزه کنیم . ما میخوایم ویژگی های فرکانس بالا با پاسخهای بزرگ رو کشف کنیم. اگه ما عملیات نرمالسازی رو در همسایگی محلی نورون برانگیخته انجام بدیم حساسیت بنسبت به همسایه هاش باز بیشتر میشه. در همین زمان این کار باعث تعدیل پاسخ هایی که بصورت یکنواخت بزرگ در هر همسایگی هستن میشه. اگه تمامی مقادیر بزرگ باشن نرمالسازی اونها باعث کاهش همه اونا میشه بنابر این ما میخوایم نوعی از **inhibition** یا بازداری رو ایجاد کنیم و نورونهای با برانگیختگی بزرگ رو تقویت کنیم. این مساله توضیحش تو بخش ۳,۳ مقاله کریژوسکی اومده ([لینک](#))


اطلاعات بیشتر در مورد [Lateral inhibition](#) رو میتونید از اینجا بخونید

من تو ترجمه **inhibition scheme** رو طرح های باز داری معنانش کردم.

دقت ان بالاتر میاید



3



<https://deeplearning.ir/%D9%85%D8%B9%D8%B1%D9%81%DB%8C-%D9%85%D8%B9%D9%85%D8%A7%D8%B1%DB%8C-resnet/>

در این لینک به طور کامل در ارائه گفته میشود




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.




Figure 5. A deeper residual function \mathcal{F} for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.

4

اول به دیتاست از تصاویر که مثل تصاویر است بدست میآوریم و شروع میکنیم رو اون دیتاست آموزش دادن شبکه و بعد که به دقت خوبی رسیدی مدل رو سیو میکنی و میای روی تصویر خودت شروع میکنی به تنظیم دقیق. معمولاً هم وقتی تعداد تصاویر کم باشه از این روش استفاده میکنن. یا اگه مدل از پیش آموزش داده شده روی تصاویر شبیه تصاویر شما وجود داره از اون هم استفاده میکنن.

5 خروجی هر لایه را به صورت شکل میتوانیم ببینیم که چه اتفاقی روی آن افتاده است

bakhshe layer#

```
[[layer_outputs = [layer.output for layer in model.layers]:12
```

Extracts the outputs of the top 12 layers #

```
activation_model = models.Model(inputs=model.input, outputs=layer_outputs) # Creates
a model that will return these outputs, given the model input
```

```
(activations = activation_model.predict(img_tensor
```

Returns a list of five Numpy arrays: one array per layer activation #

```
[first_layer_activation = activations[0
```


```
(print(first_layer_activation.shape
```

```
('plt.matshow(first_layer_activation[0, :, :, 4], cmap='viridis
```

```
activations = activation_model.predict(img_tensor) # Returns a list of five Numpy arrays:
one array per layer activation
```

```
[first_layer_activation = activations[0
```

6



['cat', 'ship', 'ship', 'airplane', 'frog', 'frog', 'automobile',
 'frog', 'cat', 'automobile', 'airplane', 'truck', 'dog',
 'horse', 'truck', 'ship']

bakhshe#

```

layer
[[layer_outputs = [layer.output for layer in model.layers[:12
Extracts the outputs of the top 12 layers #
activation_model = models.Model(inputs=model.input, outputs=layer_outputs) # Creates
a model that will return these outputs, given the model input
(activations = activation_model.predict(img_tensor
Returns a list of five Numpy arrays: one array per layer activation #
[first_layer_activation = activations[0
(print(first_layer_activation.shape
('plt.matshow(first_layer_activation[0, :, :, 4], cmap='viridis
activations = activation_model.predict(img_tensor) # Returns a list of five Numpy arrays:
one array per layer activation
[first_layer_activation = activations[0

```